

Analyse de sentiment multilingue du marché télécom marocain

Maroc Telecom · Orange Maroc · inwi — Darija / Français / Arabe (code-switching)

Ce document est un guide d'exécution, pas un rapport académique : il liste les étapes concrètes à suivre, dans l'ordre, pour construire le projet de bout en bout — de la collecte de données au dashboard final. Chaque phase indique les actions à faire, les outils recommandés et le livrable attendu à la fin.

Objectif du modèle NLP

Classifier automatiquement un commentaire client (darija / français / arabe, y compris mélangé) en **positif / négatif / neutre**, avec une comparaison rigoureuse DarijaBERT vs XLM-RoBERTa, puis associer chaque commentaire à un thème métier (réseau, prix, service client, facturation).

Vue d'ensemble des phases

1	Cadrage & collecte de données	Semaines 1-2
2	Nettoyage & prétraitement	Semaines 2-3
3	Annotation du corpus	Semaines 3-4
4	Modélisation (DarijaBERT vs XLM-R)	Semaines 4-6
5	Dashboard analytique Streamlit	Semaines 6-7
6	Finalisation & déploiement portfolio	Semaines 7-8

Cadrage et collecte de données

Définir le périmètre puis récupérer les données brutes

1 Définir le périmètre exact

Fixer les 3 opérateurs (Maroc Telecom, Orange Maroc, inwi) et les sources retenues (Google Play Store, Facebook, X/Twitter). Ne pas élargir davantage à ce stade.

Livable → Document d'une page : périmètre figé (opérateurs, sources, période couverte)

2 Scraper les avis Google Play

Extraire les avis des applications officielles des 3 opérateurs (note, texte, date).

Outils : [google-play-scraper \(Python\)](#)

Livable → Fichier CSV avis_playstore.csv

3 Scraper les commentaires Facebook

Récupérer les commentaires publics des pages officielles des opérateurs.

Outils : [Facebook Graph API si accès, sinon scraping ciblé](#)

Livable → Fichier CSV avis_facebook.csv

4 Scraper les tweets/X

Collecter les publications mentionnant les 3 marques sur une période définie.

Outils : [snsrape](#) ou [API X](#)

Livable → Fichier CSV avis_twitter.csv

5 Centraliser et stocker en brut

Fusionner les 3 sources dans un format unique avec métadonnées : date, source, opérateur, texte brut.

Livable → corpus_brut.csv (colonnes standardisées)

Nettoyage et prétraitement

Rendre le texte exploitable pour l'annotation et le modèle

6 Nettoyage de base

Supprimer emojis parasites, URLs, doublons et messages spam ou hors-sujet.

Outils : [re](#), [pandas](#)

7 Normalisation de la darija latinisée

Construire un petit dictionnaire de normalisation pour les variantes fréquentes (ex : « bzzzf » → « bezzaf »), afin de réduire le bruit orthographique.

Livable → [dictionnaire_normalisation.json](#)

8 Détection de la langue dominante

Détecter, par phrase ou par token, la langue utilisée (arabe / français / darija) pour documenter et quantifier le taux réel de code-switching dans le corpus.

Outils : [langdetect](#) / [fasttext](#) *lid.176*

9 Test des tokenizers

Comparer sur un échantillon le comportement du tokenizer DarijaBERT et de celui de XLM-RoBERTa sur des phrases mixtes, pour anticiper les problèmes de segmentation.

Livable → [corpus_nettoye.csv](#)

Annotation du corpus

Créer le jeu de données labellisé pour l'entraînement

10 Échantillonner le corpus à annoter

Sélectionner environ 1500 à 2000 commentaires représentatifs des 3 opérateurs et des 3 sources.

11 Annoter manuellement

Attribuer à chaque commentaire une étiquette positif / négatif / neutre. Optionnel : pré-labelliser avec des règles heuristiques (mots-clés) pour accélérer le travail, puis corriger.

Outils : [Label Studio](#) ou simple feuille Excel/Sheets

12 Vérifier l'équilibre des classes

Contrôler la distribution positif/négatif/neutre. Si un déséquilibre fort apparaît, envisager un ré-échantillonnage ciblé lors de l'annotation.

Livrable → corpus_annotate.csv (texte + label)

Modélisation

Entraîner, comparer et sélectionner le meilleur modèle

13 Construire une baseline simple

Entraîner un modèle TF-IDF + régression logistique comme point de référence rapide avant de passer aux transformers.

Outils : [scikit-learn](#)

14 Fine-tuner DarijaBERT

Entraîner DarijaBERT sur le corpus annoté pour la tâche de classification de sentiment.

Outils : [HuggingFace Transformers](#)

15 Fine-tuner XLM-RoBERTa

Entraîner XLM-RoBERTa sur le même jeu de données et le même découpage train/test, pour une comparaison strictement équitable.

Outils : [HuggingFace Transformers](#)

16 Comparer les deux modèles

Évaluer avec F1-score par classe, accuracy globale et matrice de confusion. Analyser spécifiquement les performances sur les phrases fortement mélangées.

Livable → Tableau comparatif + modèle retenu sauvegardé (.bin / .safetensors)

17 Extraire les thèmes de plainte

Ajouter une classification ou un topic modeling pour associer chaque commentaire à un thème (réseau, prix, service client, facturation).

Outils : [LDA \(gensim\)](#) ou [classification par mots-clés](#)

Dashboard analytique

Rendre les résultats exploitables pour la décision business

18 Construire le dashboard Streamlit

Créer les vues : comparaison de sentiment par opérateur, évolution temporelle, répartition par thème de plainte, nuage de mots par sentiment/opérateur.

Outils : [Streamlit](#), [Plotly](#), [WordCloud](#)

19 Ajouter des filtres interactifs

Permettre de filtrer par date, source et opérateur pour explorer les données dynamiquement.

20 Brancher le modèle en inférence live (optionnel)

Ajouter un champ texte libre pour tester le modèle en direct sur un nouveau commentaire.

Livrable → Application Streamlit fonctionnelle en local

Finalisation portfolio

Packager et déployer le projet pour le rendre visible

- | | |
|----|--|
| 21 | Rédiger une note de synthèse courte
Résumer méthodologie, résultats clés et limites en 1-2 pages (pas un rapport académique) : utile comme README détaillé du repo. |
| 22 | Déployer le dashboard en ligne
Mettre le dashboard en ligne pour qu'il soit consultable sans installation.
<i>Outils : Streamlit Community Cloud ou Hugging Face Spaces</i> |
| 23 | Nettoyer et documenter le repo GitHub
Structurer le code (data/, notebooks/, src/, app/), ajouter un README clair avec captures d'écran du dashboard et instructions d'installation. |
| 24 | Préparer le pitch entretien
Formuler un pitch de 2 minutes : problème → approche → résultats → impact business. Insister sur le pont entre modélisation NLP et décision Data Analyst.
Livrable → Projet complet, déployé et présentable en entretien |